Две нейросети вместо одной большой

Почему материал генерируется в два этапа: диффузионная модель SD 1.5 в её родном разрешении 512^2 и сеть сверхразрешения Real-ESRGAN до 1024^2–4096^2



Как получить карту 2048², если модель обучена на 512²

A. Одна модель сразу в итоговом разрешении

Как получается 2048²	диффузия на холсте 2048² — латент 256×256
Модель	SD 1.5 вне своего разрешения или более крупная модель (SDXL и др.)
Форма	задаётся на большом холсте
Мелкая деталь	в той же диффузии, на каждом шаге

B. Каскад из двух этапов — решение ВКР

Как получается 2048²	диффузия на 512² — латент 64×64, затем Real-ESRGAN ×4
Модели	SD 1.5 + ControlNet + LoRA (+ IP-Adapter) и Real-ESRGAN
Форма	задаётся на 512² по карте шума
Мелкая деталь	добавляется сетью сверхразрешения локально, за один проход

«Две сети» — это два этапа конвейера. Первый сам состоит из нескольких сетей (CLIP, U-Net, VAE, ControlNet, адаптер LoRA), второй — одна свёрточная сеть.

Вне обучающего разрешения диффузия ломает структуру

1 **Повторы и распад формы уже на 1024²**

SD, обученная на 512², при генерации 1024² даёт повторяющиеся объекты и неправдоподобную структуру. Причина — ограниченное поле восприятия свёрточных ядер U-Net.

He et al., ScaleCrafter, ICLR 2024

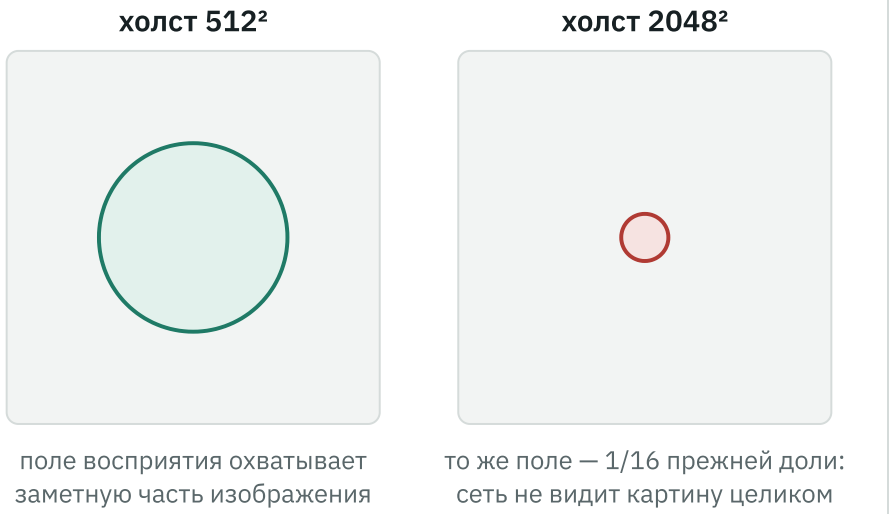
2 **Обходные методы дороже**

Генерация выше обучающего разрешения без дообучения меняет сэмплирование; DemoFusion требует больше проходов и сам начинает с изображения в исходном разрешении.

Du et al., DemoFusion, CVPR 2024

3 **Для бесшовной текстуры повтор — брак**

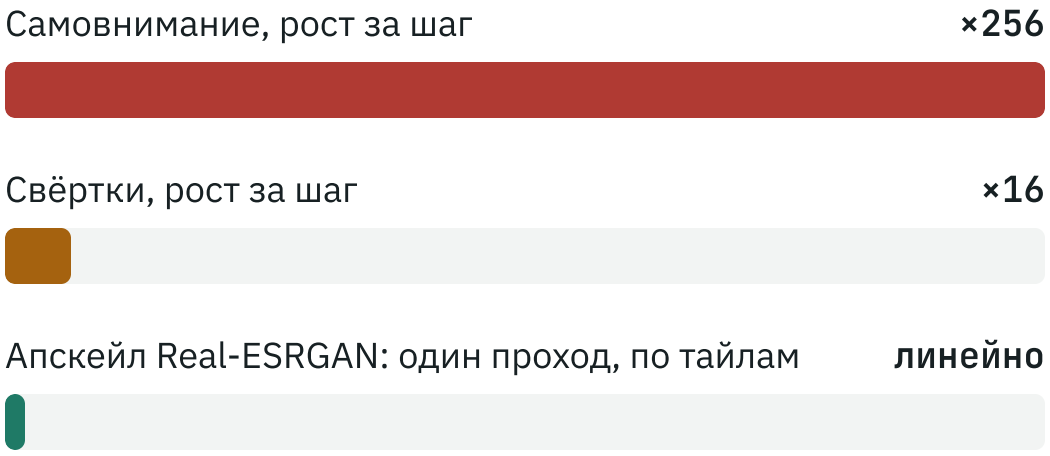
Повторяющийся фрагмент внутри плитки читается как шов, даже если края стыкуются идеально.



Холсты показаны в одном масштабе. Иллюстрация вывода ScaleCrafter: поле восприятия задано архитектурой и не растёт вместе с холстом.

Шаг диффузии на 2048² дороже в 16–256 раз

SD 1.5 (VAE уменьшает в 8 раз)	512²	2048²
Латент	64×64	256×256
Токенов в верхних блоках внимания	4 096	65 536
Свёртки — линейно по пикселям латента	**×1**	**×16**
Самовнимание — квадратично по токенам	**×1**	**×256**
Число шагов	20–40	20–40



Рост «×256» относится только к слоям самовнимания; свёрточные слои дорожают в 16 раз. Каскад платит за дорогие итерации диффузии только на 512².

Каскад — стандартный приём крупных генеративных моделей

Google Ho et al., JMLR 2022

Cascaded Diffusion Models

Модель низкого разрешения, затем модели сверхразрешения последовательно увеличивают изображение и добавляют детали. Качество выше BigGAN-deep и VQ-VAE-2 на ImageNet.

Google Saharia et al., NeurIPS 2022

Imagen: сети сверхразрешения в 3–5 раз меньше базовой



Stability AI Podell et al., ICLR 2024

SDXL: базовая модель + уточнитель

Отдельная модель-уточнитель (refiner) повышает детализацию результата базовой модели.

LMU / Runway Rombach et al., CVPR 2022

Сама SD — уже две сети

Автокодировщик сжимает изображение, диффузия работает в латентном пространстве — это значительно снижает вычислительные затраты по сравнению с диффузией в пикселях.

Тот же принцип — в NVIDIA DLSS и аналогах

NVIDIA DLSS Super Resolution

Рендер в меньшем разрешении + нейросеть

Дорогая работа делается на малом разрешении, детали итогового кадра восстанавливает нейросеть.

Meta Xiao et al., SIGGRAPH 2020 (NSRR)

На входе в 16 раз меньше пикселей

Например, 960×540 вместо 3840×2160: изображение увеличивается нейросетью в реальном времени.

NVIDIA Research Hasselgren et al., Eurographics 2020

Две сети работают вместе

Сеть адаптивного сэмплирования решает, где трассировать лучи, сеть-денойзер восстанавливает изображение; обучаются совместно.

NVIDIA ADLR DLSS 4, 2025

Сеть генерации кадров разделена пополам

Большая половина — раз на пару исходных кадров, результат переиспользуется; меньшая — на каждый новый кадр. Модель на 40 % быстрее и требует на 30 % меньше видеопамяти.

ИНЖЕНЕРНАЯ АНАЛОГИЯ

Тяжёлая часть — один раз, лёгкая — на каждый результат

NVIDIA DLSS 4 генерация кадров	**Большая половина сети** один раз на пару исходных кадров; результат переиспользуется	→	**Меньшая половина сети** на каждый из трёх сгенерированных кадров
Система ВКР генерация материала	**Диффузия 512² (20–40 шагов)** один раз; база кэшируется по хэшу параметров	→	**Real-ESRGAN, один проход** на каждое выходное разрешение 1024² · бесплатный 2048² · премиум 4096² · премиум

> Повторный экспорт в большем разрешении или переход на премиум не запускают диффузию заново — только этап сверхразрешения.

Цифры NVIDIA: ≈3,25 мс на кадр 4K у DLSS 3 (RTX 4090) и ≈1 мс на каждый из трёх кадров у DLSS 4 (RTX 5090). Измерены на разных видеокартах, поэтому напрямую не сравниваются.

Разделение частот и бесшовность на каждом этапе

Низкие и средние частоты · 512^2

Структура и раскладка

Камни, трещины, ячейки задаёт диффузия по карте шума через ControlNet — в разрешении, на котором модели обучены.

Высокие частоты · 1024^2–4096^2

Зерно и мелкие поры

Real-ESRGAN добавляет фактуру локально, по тайлам, не меняя крупную структуру.

Ограничение: сверхразрешение не добавляет новых смысловых деталей. Если на 4096^2 фактуры мало — перспектива: уточнение по тайлам диффузией (img2img, как refiner SDXL).

Бесшовность сохраняется на каждом этапе

- ↻ периодический процедурный шум
- ↻ циклический padding в U-Net, ControlNet и VAE
- ↻ перед апскейлом края дополняются на 32 px с заворачиванием, после ×4 вырезается центр
- ↻ PBR-карты считаются фильтрами с заворачиванием краёв

Chen et al., PBR-SR, NeurIPS 2025

Сверхразрешение применимо и к картам материалов: PBR-SR увеличивает PBR-текстуры готовой моделью сверхразрешения, обученной на обычных изображениях, без дообучения.

Что каскад даёт архитектуре системы

Качество формы

Диффузия работает в родном разрешении модели — без повторов и распада структуры.

Тарифы без второй модели

Бесплатный и премиум различаются этапом сверхразрешения (×2 или ×4) и числом шагов.

Кэш и повторный экспорт

База 512^2 переиспользуется для любого разрешения и любого движка.

Видеопамять

GPU-воркер целиком — ориентир 5–8 ГБ; на облачной L4 24 ГБ остаётся запас.

Дообучение в курсовой

LoRA обучается только для SD 1.5 на 512^2 — на одной потребительской видеокарте.

Заменяемость

Модель сверхразрешения меняется независимо от генерации: тот же интерфейс, другие веса.

Итог: одна обучаемая модель, одна точка кэширования, тарифы настраиваются параметрами этапов, а не отдельными моделями.

Что подтвердим замерами на L4 24 ГБ

ПОКАЗАТЕЛЬ	КАСКАД (РЕШЕНИЕ ВКР)	ПРЯМАЯ ГЕНЕРАЦИЯ
Пиковая видеопамять, ГБ	512^2 + апскейл ×2 / ×4 по тайлам	SD 1.5 напрямую в 1024^2 и 2048^2; ScaleCrafter или DemoFusion
Время до готовой карты, с	20 и 30 шагов + апскейл	те же шаги
Повторы структуры	доля текстур с повторами — экспертная оценка	то же
Соответствие описанию	CLIP score	CLIP score
Бесшовность	разница яркости по шву при плитке 3×3	то же

> До замеров в обосновании нет непроверенных чисел: только опубликованные данные и расчёт по архитектуре SD 1.5.

Литература

ГЕНЕРАТИВНЫЕ МОДЕЛИ И СВЕРХРАЗРЕШЕНИЕ

1. Ho J. et al. Cascaded Diffusion Models for High Fidelity Image Generation // JMLR. 2022. Vol. 23, No. 47. P. 1–33.
2. Saharia C. et al. Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding // NeurIPS 35. 2022. P. 36479–36494.
3. Rombach R. et al. High-Resolution Image Synthesis with Latent Diffusion Models // CVPR. 2022. P. 10674–10685.
4. Podell D. et al. SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis // ICLR. 2024. arXiv:2307.01952.
5. He Y. et al. ScaleCrafter: Tuning-free Higher-Resolution Visual Generation with Diffusion Models // ICLR. 2024. arXiv:2310.07702.
6. Du R. et al. DemoFusion: Democratising High-Resolution Image Generation With No $$$ // CVPR. 2024. P. 6159–6168.
7. Wang X., Xie L., Dong C., Shan Y. Real-ESRGAN // ICCV Workshops. 2021. P. 1905–1914.
8. Zhang L., Rao A., Agrawala M. Adding Conditional Control to Text-to-Image Diffusion Models // ICCV. 2023. P. 3813–3824.

МАТЕРИАЛЫ И ГРАФИКА РЕАЛЬНОГО ВРЕМЕНИ

9. Vecchio G. et al. MatFuse: Controllable Material Generation with Diffusion Models // CVPR. 2024. P. 4429–4438.
10. Chen Y. et al. PBR-SR: Mesh PBR Texture Super Resolution from 2D Image Priors // NeurIPS. 2025. arXiv:2506.02846.
11. Hasselgren J. et al. Neural Temporal Adaptive Sampling and Denoising // Computer Graphics Forum. 2020. Vol. 39, No. 2. P. 147–155.
12. Xiao L. et al. Neural Supersampling for Real-Time Rendering // ACM TOG. 2020. Vol. 39, No. 4. Art. 142.
13. DLSS 4: Transforming Real-Time Graphics with AI / NVIDIA ADLR. 2025. URL: research.nvidia.com/labs/adlr/DLSS4
14. NVIDIA DLSS 4 Introduces Multi Frame Generation // NVIDIA GeForce News. 2025.

Полные описания по ГОСТ Р 7.0.100–2018 с DOI — в заметке «Обоснование каскада двух сетей» (раздел нейросетевых моделей).

ВЫВОД

Каскад из двух этапов — осознанный инженерный выбор

- ✓ Диффузия работает в разрешении, на котором обучена: форма точно следует процедурному шуму, без повторов.
- ✓ Тот же принцип применяют Google (Imagen, Cascaded Diffusion), Stability AI (SDXL) и NVIDIA (DLSS): дорогая модель — на малом разрешении, лёгкая сеть — на детали.
- ✓ Для системы это кэш базы 512^2, тарифы без второй модели и запас видеопамяти; цифры подтвердим замерами на L4.